

基于图模型的癌细胞-T 细胞通讯分析

本实验利用肺癌（LungTumor）/结直肠癌（ColonTumor）/乳腺癌（BreastTumor）的单细胞转录组数据，进行基于**最小生成树**的癌细胞（CancerCell）与 T 细胞（TCell）通讯分析。具体地，选用自己最为熟悉的编程语言，实现以下步骤：

（1）针对某一癌症类型，计算每个基因在每种细胞类型（癌细胞类型/T 细胞类型）中表达水平的“方差”，进而筛选前 1000 个表达高变（方差大）的基因作为节点，分别构建癌细胞类型和 T 细胞类型的无向完全图。图中的每条边称为 **Intracellular Edge**。请注意图中节点的标识符定义为“基因名/CancerCell”或“基因名/TCell”；

（2）依据已知的 1942 个配体—受体相互作用（存储在 LigandReceptor_Human.txt），连接癌细胞类型的无向完全图与 T 细胞类型的无向完全图。用来连接这两个无向完全图的边称为 **Intercellular Edge**。请注意对于每个配体—受体相互作用，可能存在 2 条 **Intercellular Edges**,即“配体基因名/CancerCell—受体基因名/Tcell”和“配体基因名/Tcell—受体基因名/CancerCell”；

（3）**Intracellular Edge** 的权重（边代价）定义为： $1-\text{MinMax}(\text{abs}(\text{Spearman 相关系数}))$ ，其中 Spearman 相关系数指的是 **Intracellular Edge** 所连接的两个基因的表达水平之间的 Spearman 相关系数。该定义使得 **Intracellular Edge** 所连接的两个基因的表达水平相关性越高，边权越小；

（4）**Intercellular Edge** 的权重（边代价）定义为： $1-\text{MinMax}(\text{配体基因和受体基因分别在两种细胞类型所有细胞中表达的均值的乘积})$ 。该定义使得 **Intercellular Edge** 所连接的配体基因和受体基因的表达水平越高，边权越小；

（5）至此，已构建出一个跨细胞类型的带权无向图，请识别该图的最小生成树；

（6）**细胞通讯信号通路可视化**：针对 InputData 目录下的每种癌症数据，请完成上述 5 个步骤，进而展示三种癌症的最小生成树中 **Intercellular Edges** 及其向两端延展的 5 阶邻居，作为最终识别的癌细胞-T 细胞通讯信号通路；

（7）**关键基因分析**：比较三种癌症之间最小生成树中节点“度中心性”前 50 名的异同，结果以韦恩图展示；

（8）**关键基因分析**：比较三种癌症之间最小生成树中节点“介数中心性”前 50 名的异同，结果以韦恩图展示。

输入数据解释：

- 1) 上述三种癌症的单细胞转录组数据存放于 `InputData/` 目录下，每种癌症有 2 个 `csv` 文件，分别存储“癌细胞类型 (`CancerCell`)”和“T 细胞类型 (`TCell`)”的基因表达矩阵，文件命名规则为“癌症类型_细胞类型_GeneExpression.csv”。每个 `csv` 文件中存储的基因表达矩阵的行名为基因名，列名为细胞名，矩阵中的值为某个基因（行）在某个细胞（列）中的表达水平。
- 2) `LigandReceptor_Human.txt` 中存储了 1942 个配体—受体相互作用，第一列为配体 (`Ligand`) 基因名，第二列为受体 (`Receptor`) 基因名。

函数符号解释：

`MinMax()`：最小-最大标准化（归一化）函数；

`abs()`：取绝对值函数。

实验报告与小论文提交方式：

请将**代码脚本文件**、**实验报告 PDF 版**、**小论文（实验报告扩展）PDF 版**打包为 `zip` 文件，命名为“学号 - 姓名 - 生物信息学算法 .zip”，发送至 BioinfoAlgorithm@163.com